

# Econometria I — Gabarito

25/09/2025

## Gabarito — Questão 1

Considere

$$y = X_1\beta_1 + X_2\beta_2 + \varepsilon,$$

com  $X_1$  de dimensão  $n \times k_1$  e  $X_2$  de dimensão  $n \times k_2$ . Defina  $X = [X_1 \ X_2]$ .

### (a) Derivação de $b_2$ (duas rotas, equivalentes)

Antes das rotas, defina o operador residual-maker:

$$M_1 \equiv I_n - X_1(X_1'X_1)^{-1}X_1',$$

com propriedades:  $M_1' = M_1$ ,  $M_1^2 = M_1$  e  $M_1X_1 = 0$ . Intuitivamente,  $M_1$  projeta vetores no subespaço ortogonal ao espaço gerado por  $X_1$  — ou seja, retorna resíduos de regressões sobre  $X_1$ .

### Rota A — *Residualização / partialling out*

1. Aplique  $M_1$  ao modelo:

$$M_1y = M_1X_1\beta_1 + M_1X_2\beta_2 + M_1\varepsilon.$$

Como  $M_1X_1 = 0$ , resulta

$$M_1y = M_1X_2\beta_2 + M_1\varepsilon.$$

2. Denote  $y^* = M_1y$  e  $X_2^* = M_1X_2$ . O modelo torne-se

$$y^* = X_2^*\beta_2 + M_1\varepsilon.$$

3. O MQO de  $\beta_2$  pela regressão de  $y^*$  em  $X_2^*$  é

$$\hat{\beta}_2 = (X_2^{*'}X_2^*)^{-1}X_2^{*'}y^*.$$

4. Como  $X_2^{*'}X_2^* = X_2'M_1X_2$  e  $X_2^{*'}y^* = X_2'M_1y$  (usando  $M_1' = M_1$  e  $M_1^2 = M_1$ ), obtemos

$$\hat{\beta}_2 = (X_2'M_1X_2)^{-1}X_2'M_1y.$$

## Rota B — Equações normais particionadas

1. Escreva as normais particionadas:

$$\begin{pmatrix} X_1'X_1 & X_1'X_2 \\ X_2'X_1 & X_2'X_2 \end{pmatrix} \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} X_1'y \\ X_2'y \end{pmatrix}.$$

2. Da primeira equação:

$$b_1 = (X_1'X_1)^{-1}(X_1'y - X_1'X_2b_2).$$

3. Substitua na segunda equação e reorganize; realiza-se a fatoração

$$X_2'X_2 - X_2'X_1(X_1'X_1)^{-1}X_1'X_2 = X_2'M_1X_2,$$

e o termo à direita se reduz a  $X_2'M_1y$ . Assim:

$$X_2'M_1X_2 b_2 = X_2'M_1y \Rightarrow b_2 = (X_2'M_1X_2)^{-1}X_2'M_1y.$$

---

### (b) Interpretação — *partialling out*

A expressão mostra que  $\hat{\beta}_2$  equivale à regressão dos resíduos de  $y$  (após remover o que  $X_1$  explica) sobre os resíduos de cada coluna de  $X_2$  (após remover o que  $X_1$  explica). Em termos econômicos,  $\hat{\beta}_2$  mede o efeito de variações em  $X_2$  **que não estão correlacionadas com  $X_1$**  — isto é, o efeito “ceteris paribus” de  $X_2$ .

---

### (c) Caso $X_1$ é vetor de constantes

Se  $X_1$  é a coluna de 1's, então  $M_1$  centraliza variáveis (subtrai a média). Logo  $M_1X_2$  contém as colunas de  $X_2$  em desvios em relação às médias, e  $M_1y$  é  $y - \bar{y}$ . Assim  $\hat{\beta}_2$  é a regressão de desvios  $y - \bar{y}$  sobre  $X_2 - \bar{X}_2$  — a interpretação usual de coeficientes em regressão com intercepto.

## Gabarito — Questão 2

Modelo verdadeiro:

$$y = X\beta + \varepsilon = X_1\beta_1 + X_2\beta_2 + \varepsilon,$$

estimador (incorreto) usado:

$$\tilde{\theta} = (X_1'X_1)^{-1}X_1'y.$$

(a) **Viés condicional**  $E[\tilde{\theta} | X] - \beta_1$

Substitua  $y = X_1\beta_1 + X_2\beta_2 + \varepsilon$  em  $\tilde{\theta}$ :

$$\tilde{\theta} = (X_1'X_1)^{-1}X_1'(X_1\beta_1 + X_2\beta_2 + \varepsilon) = \beta_1 + (X_1'X_1)^{-1}X_1'X_2\beta_2 + (X_1'X_1)^{-1}X_1'\varepsilon.$$

Tomando esperança condicional em  $X$  (assumindo  $E[\varepsilon | X] = 0$ ):

$$E[\tilde{\theta} | X] = \beta_1 + (X_1'X_1)^{-1}X_1'X_2\beta_2.$$

Portanto o viés condicional é

$$\text{Bias}(\tilde{\theta} | X) = (X_1'X_1)^{-1}X_1'X_2\beta_2.$$

**Interpretação:** se  $X_1'X_2 \neq 0$  (colinearidade entre as colunas incluídas e as omitidas) e  $\beta_2 \neq 0$ , a omissão gera viés. Se  $X_1'X_2 = 0$  (ortogonalidade exata) ou  $\beta_2 = 0$  (variáveis omitidas irrelevantes), o viés é zero.

---

(b) **Condições para consistência** ( $\tilde{\theta} \xrightarrow{p} \beta_1$ )

A partir da decomposição:

$$\tilde{\theta} - \beta_1 = (X_1'X_1)^{-1}X_1'X_2\beta_2 + (X_1'X_1)^{-1}X_1'\varepsilon.$$

Dividindo termos por  $n$  e tomando limites em probabilidade, sufixe  $Q = \text{plim } \frac{1}{n}X_1'X_1$ . Condições suficientes (hipóteses padrão):

1.  $(x_i, \varepsilon_i)$  i.i.d.;
2.  $\frac{1}{n}X_1'X_1 \xrightarrow{p} Q$  com  $Q$  positivo definido;
3.  $\frac{1}{n}X_1'X_2 \xrightarrow{p} 0$  (ortogonalidade assintótica entre  $X_1$  e  $X_2$ );
4.  $\frac{1}{n}X_1'\varepsilon \xrightarrow{p} 0$  (por LGN, se  $E[x_i\varepsilon_i] = 0$ ).

Se (3) e (4) valem, então

$$\text{plim } \tilde{\theta} = \beta_1 + Q^{-1} \cdot 0 + 0 = \beta_1,$$

ou seja  $\tilde{\theta}$  é consistente.

**Interpretação econômica:** A condição  $\frac{1}{n}X_1'X_2 \rightarrow 0$  significa que, no limite, as covariâncias amostrais entre os regressores observados e os omitidos anulam-se — em termos práticos é uma condição forte; só em situações específicas (ex.: variáveis omitidas não correlacionadas com as incluídas em média) ou quando os efeitos das correlações se diluem com amostras maiores, teremos consistência.

---

(c) **Variância assintótica (sob as condições de (b))**

Partimos da representação exata (substituindo  $y = X_1\beta_1 + X_2\beta_2 + \varepsilon$  em  $\tilde{\theta}$ ):

$$\tilde{\theta} - \beta_1 = (X_1'X_1)^{-1}X_1'X_2\beta_2 + (X_1'X_1)^{-1}X_1'\varepsilon.$$

Sob as hipóteses padrão de amostras grandes, suponha que

$$\frac{1}{n}X_1'X_1 \xrightarrow{p} Q, \quad Q \text{ é positiva definida,}$$

e que as componentes  $x_{1i}\varepsilon_i$  satisfazem as condições do teorema central (momento de segunda ordem finito e independência ou condições que garantem o CLT multivariado). Então podemos analisar o segundo termo estocástico por meio do CLT:

1. Note que

$$\frac{1}{\sqrt{n}}X_1'\varepsilon = \frac{1}{\sqrt{n}}\sum_{i=1}^n x_{1i}\varepsilon_i \xrightarrow{d} N(0, \sigma^2 Q),$$

pois  $E[x_{1i}\varepsilon_i] = 0$  e  $\text{Var}(x_{1i}\varepsilon_i) = \sigma^2 E[x_{1i}x_{1i}'] = \sigma^2 Q$ .

2. Escreva

$$\begin{aligned} \sqrt{n}(\tilde{\theta} - \beta_1) &= \left(\frac{1}{n}X_1'X_1\right)^{-1} \left(\frac{1}{\sqrt{n}}X_1'\varepsilon\right) \\ &\quad + \sqrt{n}\left(\frac{1}{n}X_1'X_1\right)^{-1} \left(\frac{1}{n}X_1'X_2\right) \beta_2. \end{aligned}$$

3. Se, nas condições de consistência,  $\frac{1}{n}X_1'X_2 \rightarrow 0$ , o segundo termo tende a zero e a distribuição limite decorre apenas do primeiro termo. Usando que  $\frac{1}{n}X_1'X_1 \xrightarrow{p} Q$  e o resultado do passo 1, obtemos:

$$\sqrt{n}(\tilde{\theta} - \beta_1) \xrightarrow{d} N(0, \sigma^2 Q^{-1}).$$

Logo a variância assintótica (do vetor) é

$$\text{Asy. Var}(\tilde{\theta}) = \sigma^2 Q^{-1}, \quad Q = \text{plim} \frac{1}{n}X_1'X_1.$$

**Como estimar na prática:** substituir  $\sigma^2$  por  $s^2 = \hat{\varepsilon}'\hat{\varepsilon}/(n - K_1)$  (resíduo do modelo com  $X_1$ ) e  $Q$  por  $(1/n)X_1'X_1$ , obtendo o estimador consistente

$$\widehat{\text{Asy. Var}}(\tilde{\theta}) \approx s^2(X_1'X_1)^{-1}.$$

(d)  $\frac{1}{n}X_1'X_2 \not\rightarrow 0$  — **efeito da correlação entre  $X_1$  e  $X_2$**

Neste caso a condição que garantia a eliminação do termo determinístico  $(X_1'X_1)^{-1}X_1'X_2\beta_2$  **não vale**; portanto o estimador  $\tilde{\theta}$  **não é consistente** (plim deslocado). Focando, porém, na influência da correlação entre  $X_1$  e  $X_2$  sobre a variância (o que a questão pede), temos o seguinte ponto simples e central:

- A correlação entre colunas de  $X_1$  e colunas de  $X_2$  aumenta o grau de multicolinearidade percebido pelas regressões que envolvem  $X_1$ . A variância condicional de um coeficiente  $b_k$  pode ser escrita (no caso univariado para a coordenada  $k$ ) como

$$\text{Var}[\hat{b}_k | X] = \frac{\sigma^2}{(1 - R_k^2) \sum_i (x_{ik} - \bar{x}_k)^2},$$

onde  $R_k^2$  é o  $R^2$  da regressão de  $x_k$  sobre as demais colunas do design matrix. A presença de forte correlação entre as regressoras eleva  $R_k^2$  (pois  $x_k$  é bem explicado pelas outras variáveis), e, por conseguinte, **aumenta a variância** de  $\hat{b}_k$  através do fator  $1/(1 - R_k^2)$  (o VIF).

- Aplicando essa lógica ao nosso contexto: se  $X_1$  e  $X_2$  são altamente correlacionados, então as colunas de  $X_1$  serão bem explicadas por  $X_2$  (e vice-versa), o que implica  $R_k^2$  alto para as colunas em  $X_1$ . Consequentemente, mesmo ao considerar chegar a variância assintótica (mesmo que hipoteticamente tivéssemos consistência), o efeito é **inflacionar** a variância estimada dos coeficientes associados a  $X_1$ .
- **Observação breve (gravidade):** embora a inflação da variância seja um problema relevante (torna as estimativas imprecisas), a **inconsistência** (viés assintótico) resultante de  $\frac{1}{n} X_1' X_2 \not\rightarrow 0$  é conceitualmente mais grave: mesmo com amostras grandes o estimador converge para um valor errado. Ainda assim, do ponto de vista da inferência sobre os coeficientes, a correlação elevada aumenta o erro padrão (via  $1/(1 - R_k^2)$ ), tornando estimativas menos confiáveis.

## Gabarito — Questão 3

Modelo particionado:

$$y = X\beta + z\gamma + \varepsilon,$$

onde  $X$  é  $n \times K$  e  $z$  é  $n \times 1$  (para simplificar a notação; extensão trivial a vetor  $z$ ).

### (a) Viés ao omitir $z$

Se omitimos  $z$  e estimamos  $y = X\tilde{\beta} + u$ , o estimador é

$$\tilde{\beta} = (X'X)^{-1}X'y.$$

Substituindo  $y = X\beta + z\gamma + \varepsilon$ :

$$\tilde{\beta} = (X'X)^{-1}X'(X\beta + z\gamma + \varepsilon) = \beta + (X'X)^{-1}X'z\gamma + (X'X)^{-1}X'\varepsilon.$$

Tomando esperança condicional:

$$E[\tilde{\beta} | X, z] = \beta + (X'X)^{-1}X'z\gamma.$$

Logo o viés (condicional) é

$$\boxed{\text{Bias}(\tilde{\beta} | X, z) = (X'X)^{-1}X'z\gamma}.$$

Se  $X'z \neq 0$  e  $\gamma \neq 0$  existe viés. Se  $X'z = 0$  ou  $\gamma = 0$  não há viés.

(b) Comparação de variâncias (incluir vs omitir  $z$ )

**Variância quando omitimos  $z$ :** (var condicional dado  $X$ )

$$\text{Var}[\tilde{\beta} \mid X] = \sigma^2(X'X)^{-1}.$$

**Variância do estimador de  $\beta$  quando incluímos  $z$ :** trate o modelo completo com regressoras  $[X \ z]$ . Pelo Teorema FWL, o estimador de  $\beta$  no modelo completo é

$$\hat{\beta} = (X'M_zX)^{-1}X'M_zy,$$

onde  $M_z = I - z(z'z)^{-1}z'$ . A variância condicional é

$$\text{Var}[\hat{\beta} \mid X, z] = \sigma^2(X'M_zX)^{-1}.$$

Compare  $X'M_zX$  com  $X'X$ :

$$X'M_zX = X'(I - z(z'z)^{-1}z')X = X'X - X'z(z'z)^{-1}z'X.$$

Note que  $X'z(z'z)^{-1}z'X$  é uma matriz simétrica positiva semidefinida, então

$$X'M_zX \preceq X'X \quad (\text{em relação à ordem de semidefinitude}).$$

Quando  $A \preceq B$  para matrizes PD, então  $A^{-1} \succeq B^{-1}$ . Assim:

$$(X'M_zX)^{-1} \succeq (X'X)^{-1},$$

o que implica (em sentido de matrizes de covariância) que

$$\text{Var}[\hat{\beta} \mid X, z] \succeq \text{Var}[\tilde{\beta} \mid X].$$

Em palavras: **incluir**  $z$  (uma variável adicional) costuma **aumentar** a variância dos coeficientes de  $X$  (a precisão diminui), porque o fator  $X'M_zX$  é menor que  $X'X$ , fazendo seu inverso maior. Essa é a manifestação matricial do efeito de multicolinearidade/ perda de graus de liberdade.

---

(c) Dilema viés vs precisão

- **Omissão de  $z$ :** gera **viés** (se  $X'z \neq 0$  e  $\gamma \neq 0$ ); porém o estimador omitido tem **menor variância** (mais preciso) do que o estimador que inclui  $z$  — trade-off: menos viés  $\times$  mais precisão (mas viés pode ser grave e levar a inferências erradas).
- **Inclusão de  $z$ :** elimina o viés (se  $z$  for o verdadeiro determinante omitido) tornando os estimadores não-viesados (sob exogeneidade), porém aumenta a variância dos coeficientes já presentes (particularmente se  $z$  for altamente correlacionado com colunas de  $X$ ). Em presença de forte multicolinearidade, os coeficientes podem se tornar imprecisos (intervalos largos).

**Conclusão:** a escolha entre incluir ou omitir regressores envolve trade-offs. Em aplicações, a preferência recai geralmente por incluir variáveis relevantes (evitar viés), mesmo em custo de maior variância; quando a inclusão provoca instabilidade (multicolinearidade severa), alternativas como coleta de mais dados, transformação, uso de proxies ou regularização podem ser consideradas.

## Gabarito — Questão 4

Modelo estimado:

$$yield_i = \alpha_0 + \alpha_1 fertilizer_i + v_i,$$

com  $\hat{\alpha}_1 = 0.45$  (significativo). Variável omitida: `soil_quality_i`, que é positivamente correlacionada tanto com `fertilizer` quanto com `yield`.

### Interpretação e viés

Se o modelo verdadeiro incluir `soil_quality_i`, por exemplo

$$yield_i = \beta_0 + \beta_1 fertilizer_i + \beta_2 soil\_quality_i + u_i,$$

mas estimamos sem `soil_quality`, então conforme derivado nas questões anteriores o estimador obtido por regressão de `yield` em `fertilizer` é

$$\tilde{\alpha}_1 = \beta_1 + \frac{\text{Cov}(fertilizer, soil\_quality)}{\text{Var}(fertilizer)} \beta_2 + \text{estocástico}.$$

Como a hipótese do enunciado afirma que `soil_quality` está positivamente correlacionada com `fertilizer` ( $\text{Cov} > 0$ ) e também aumenta o `yield` (esperamos  $\beta_2 > 0$ ), o termo  $\frac{\text{Cov}(\cdot)}{\text{Var}(\cdot)} \beta_2$  é **positivo**. Assim:

- $\hat{\alpha}_1$  é **viesado para cima** (superestimação) do efeito causal verdadeiro  $\beta_1$ .
- A magnitude observada de 0.45 pode, portanto, incorporar tanto o efeito causal do fertilizante quanto o efeito da qualidade do solo que está correlacionado com fertilizante.

**Conclusão sobre a interpretação:** não podemos interpretar  $\hat{\alpha}_1 = 0.45$  como o efeito causal do fertilizante sem tratar a omissão de `soil_quality`. O estimador é consistente apenas se `soil_quality` for irrelevante ( $\beta_2 = 0$ ) ou se `soil_quality` for, de alguma forma, ortogonal ao `fertilizer` (não é o caso aqui).

---

### Controle / uso de proxies e alteração da estimativa

- **Incluir `soil_quality` diretamente:** se existir uma medida confiável de `soil_quality` (ou um índice objetivo), incluí-la no regressor corrige o viés (reduzindo ou eliminando o termo de omissão), levando a uma estimativa mais próxima do efeito causal verdadeiro  $\beta_1$ . Pode-se então obter  $\hat{\beta}_1$  não-viesado (sob sup. de exogeneidade condicional).
- **Usar proxy de `soil_quality`:** se só houver uma proxy indireta (ex.: tipo de terreno, índice pluviométrico histórico, mapas de fertilidade), incluir essa proxy pode reduzir parcialmente o viés. Importante: proxy imperfeita gera **measurement error** na variável de controle, o que pode introduzir novo viés (attenuation) — mas geralmente é preferível a omissão total (este ponto sobre measurement error não precisa fazer parte da resposta, já que ainda iremos discutir este assunto).

- **Por que a estimativa muda substancialmente:** ao controlar por `soil_quality` (ou proxy informativa), parte da covariância entre `fertilizer` e `yield` que antes era atribuída ao fertilizante será agora explicada pela qualidade do solo; assim o coeficiente de `fertilizer` tende a diminuir (se parte do efeito observado vinha de `soil_quality`). Em muitos estudos agrícolas, o coeficiente bruta cai substancialmente após controle por qualidade do solo, confirmando a presença de OVB.
- 

### Importância da exogeneidade e consistência

- A condição crucial para que a estimativa do coeficiente seja consistente é **exogeneidade condicional**:  $E[u_i | fertilizer_i, soil\_quality_i] = 0$ . Se existir simultaneidade (por exemplo políticas locais que subsidiam fertilizantes em solos ruins) ou erros de medição correlacionados com os regressores, a consistência falha.
  - **Se a proxy estiver correlacionada com o erro**, a inclusão pode não resolver o problema e pode até introduzir vieses adicionais. Avaliar a qualidade da proxy (como ela se correlaciona com `soil_quality` e com o erro) é crucial.
- 

### Recomendações empíricas (práticas)

1. Incluir controles de qualidade do solo quando disponíveis; se só houver proxies, reportar resultados com e sem proxy e discutir possíveis vieses residuais.
  2. Realizar testes de sensibilidade (ex.: variações regionais, inclusão de fixed effects municipais, uso de dados de painéis se disponíveis).
  3. Se suspeitar de endogeneidade persistente, considerar estratégias alternativas: instrumentos válidos (IV) para `fertilizer` — por exemplo distância a centros de distribuição, políticas exógenas — ou desenho quasi-experimental.
- 

**Resumo final:** Diante da omissão de `soil_quality` (positivamente correlacionada com fertilizante e `yield`) o coeficiente estimado é provavelmente **superestimado**; controlar por `soil_quality` (ou uma boa proxy) é essencial para recuperar a interpretação causal correta.